



SP-3068: Fundamentos para el aprendizaje de máquinas (aprendizaje estadístico)

Nombre del Programa: Programa de Posgrado en Ciencias Cognoscitivas

Plan de Estudios al que pertenece el curso: Maestría Académica

Modalidad: Teórico-práctico

Tipo de entorno: Presencial

Grado de virtualidad: Bajo virtual

Horas semanales: 3

Profesor que lo imparte: Marcelo Araya Salas PhD (marcelo.araya@ucr.ac.cr; sitio web:

<https://marce10.github.io/>)

Sitio web del curso: https://marce10.github.io/aprendizaje_estadistico_2024

Horas de consulta: Martes 4 pm (oficina 2, Centro de Investigación en Neurociencias)

Justificación

El aprendizaje estadístico, también conocido como aprendizaje de máquinas o automático o "machine learning," es una rama de la inteligencia artificial que se enfoca en el desarrollo de algoritmos y modelos que permiten a las computadoras aprender patrones y hacer predicciones para tomar decisiones basadas en datos. En lugar de seguir instrucciones explícitas para realizar una tarea, estos algoritmos identifican patrones en los datos y usan estos patrones para mejorar su desempeño en tareas específicas. El aprendizaje estadístico se utiliza en una amplia variedad de aplicaciones, desde el reconocimiento de voz hasta el análisis de grandes conjuntos de datos y la automatización de procesos industriales. En este curso los estudiantes podrán conocer los fundamentos y las técnicas básicas del aprendizaje estadístico para responder preguntas de investigación en Ciencias Cognoscitivas. Al iniciar el curso, se espera que las y los estudiantes conozcan los aspectos básicos de la estadística descriptiva e inferencial y el manejo básico del lenguaje de programación y análisis estadístico R.

Objetivo General

Capacitar a los estudiantes en los fundamentos, historia y diversas aplicaciones del aprendizaje de máquinas en el contexto de las Ciencias Cognoscitivas.

Objetivos Específicos

Al finalizar el curso, los estudiantes deberán ser capaces de:

- Describir y explicar los conceptos y métodos principales del aprendizaje estadístico aplicados a las Ciencias Cognoscitivas.
- Diferenciar entre los tipos de aprendizaje estadístico: supervisado, no supervisado, semi-supervisado y por reforzamiento.
- Comprender los fundamentos teóricos y los supuestos de técnicas como la regresión, las redes neuronales, los árboles de decisión y el análisis de conglomerados.
- Implementar, en el lenguaje de programación R, las técnicas desarrolladas a lo largo del curso.
- Seleccionar la técnica más adecuada en función del problema práctico o pregunta de investigación en las diversas áreas de las Ciencias Cognoscitivas.

Contenidos

Introducción al Aprendizaje Estadístico



Introducción a la estadística y su relación con el aprendizaje estadístico
Diferencias y similitudes entre inteligencia artificial, aprendizaje estadístico y ciencia de datos
Aplicaciones del aprendizaje estadístico en las Ciencias Cognoscitivas

Introducción a R

Instalación y configuración de R y RStudio
Estructuras de datos en R: vectores, matrices, listas y data frames
Manipulación de datos con funciones base R
Introducción a la visualización de datos con gráficos base R
Escribir funciones y usar loops en R

Simulación de Datos con Patrones Predefinidos

Generación de datos simulados en R
Creación de patrones específicos para análisis
Implementación en R y prácticas con simulación de datos

Regresión Lineal

Modelo de regresión lineal
Supuestos del modelo de regresión lineal
Evaluación del modelo: R^2 , error estándar, test F
Implementación en R y prácticas con modelos lineales simples

Regresión Lineal Múltiple

Modelo de regresión lineal múltiple
Supuestos adicionales y diagnóstico del modelo
Regresión con interacciones y variables categóricas
Implementación en R y prácticas con modelos múltiples

Métodos de Clasificación

Regresión logística
Análisis discriminante lineal y cuadrático
K-vecinos más cercanos (KNN)
Implementación en R y prácticas con métodos de clasificación

Métodos de Remuestreo

Validación cruzada
Bootstrap
Implementación en R y prácticas con técnicas de remuestreo

Selección y Regularización de Modelos

Subconjunto, Ridge y Lasso
Comparación de modelos y criterios de selección
Implementación en R y prácticas con técnicas de regularización



Modelos de Árboles de Decisión

Introducción a los árboles de decisión
Árboles de clasificación y regresión
Implementación en R y prácticas con árboles de decisión

Modelos de Ensamblado

Bagging y Random Forests
Boosting
Implementación en R y prácticas con modelos de ensamblado

Máquinas de Soporte Vectorial

Introducción a las SVMs
Kernels y clasificación no lineal
Implementación en R y prácticas con SVMs

Redes Neuronales y Deep Learning

Introducción a las redes neuronales
Perceptrón y neurona sigmoide
Arquitectura de redes neuronales
Algoritmo de propagación hacia atrás
Implementación en R y prácticas con redes neuronales

Redes Neuronales y Deep Learning Avanzado

Modelos de deep learning
Redes convolucionales y recurrentes
Implementación en R y prácticas avanzadas

Análisis de Conglomerados

Introducción al análisis de conglomerados
K-means y jerárquico
Implementación en R y prácticas con análisis de conglomerados

Reducción de Dimensionalidad

Análisis de componentes principales (PCA)
Análisis de discriminante lineal (LDA)
Implementación en R y prácticas con técnicas de reducción de dimensionalidad

Método

Se utilizará la plataforma de Mediación Virtual de la Universidad de Costa Rica como un recurso complementario para el acceso a los *scripts*, la entrega de las tareas y la comunicación entre el profesor y el estudiantado. Las sesiones teóricas y prácticas del curso serán presenciales. El método utilizado combina clases magistrales, demostraciones con software de algunos de los procedimientos de análisis de datos, y



ejercicios prácticos que los y las estudiantes resolverán. Cuando se realicen los ejercicios prácticos, los resultados se discutirán en la clase para propiciar la interacción entre docente y estudiantes.

Evaluación

Tareas (60%)

Cada estudiante, de manera individual, deberá realizar 3 tareas con un valor de 20% cada una. En estas tareas, el estudiantado pondrá en práctica los conocimientos y destrezas abordados durante las sesiones presenciales del curso. Las tareas están diseñadas para evaluar la comprensión y aplicación de los conceptos teóricos y prácticos vistos en clase. Las tareas pueden incluir, pero no se limitan a:

- Implementación de algoritmos de aprendizaje estadístico en R.
- Análisis de datos utilizando técnicas de visualización y preprocesamiento.
- Resolución de problemas específicos utilizando modelos predictivos y de clasificación.
- Comparación y evaluación de diferentes métodos de aprendizaje estadístico.

Trabajo Final (40%)

El trabajo final tiene un valor de 40% y consiste en un proyecto integrador donde los estudiantes aplicarán todos los conocimientos adquiridos durante el curso para resolver un problema práctico. A continuación se detalla la estructura y los requisitos del trabajo final:

1. Selección del Problema (10%)

- Los estudiantes deben elegir un problema de investigación o un caso práctico relevante en el contexto de las Ciencias Cognoscitivas.
- El problema seleccionado debe permitir la aplicación de técnicas de aprendizaje estadístico vistas en el curso.

2. Recopilación y Preprocesamiento de Datos (10%)

- Recopilación de un conjunto de datos adecuado para abordar el problema seleccionado.
- Realización de un preprocesamiento completo de los datos, incluyendo limpieza, transformación y visualización inicial.

3. Desarrollo e Implementación de Modelos (40%)

- Selección de al menos tres técnicas de aprendizaje estadístico diferentes para abordar el problema.
- Implementación de los modelos seleccionados en R, con una explicación detallada de los supuestos y parámetros utilizados.
- Evaluación comparativa de los modelos implementados utilizando métricas adecuadas (e.g., precisión, recall, F1-score, RMSE).

4. Análisis y Discusión de Resultados (20%)

- Interpretación de los resultados obtenidos de cada modelo.
- Discusión sobre las ventajas y desventajas de cada técnica aplicada en el contexto del problema seleccionado.
- Identificación de posibles mejoras y futuras direcciones de investigación.

5. Presentación y Reporte Final (20%)

- Elaboración de un reporte escrito que incluya introducción, metodología, resultados, discusión y conclusiones.
- Preparación de una presentación oral de 20-30 minutos (incluyendo preguntas) donde se expongan los principales hallazgos y se responda a preguntas del instructor y compañeros.

El trabajo final permitirá a los estudiantes demostrar su capacidad para integrar y aplicar de manera crítica y creativa los conceptos y técnicas aprendidas a lo largo del curso. Además, les proporcionará una experiencia práctica que refuerce sus habilidades en el uso de R y en la resolución de problemas reales mediante el aprendizaje estadístico.

Contenidos por sesión (3 horas semanales)



Día 1: Introducción a R para el Aprendizaje Estadístico - Parte 1

Introducción al aprendizaje estadístico
Instalación de R y RStudio
Navegación en el entorno de RStudio
Estructuras de datos básicas: vectores, matrices y listas
Operaciones básicas y funciones en R
Práctica con R: Crear y manipular vectores y data frames. Uso de funciones básicas

Lectura: *Badillo et al (2020). An introduction to machine learning.*
<https://ascpt.onlinelibrary.wiley.com/doi/full/10.1002/cpt.1796>

Día 2: Introducción a R para el Aprendizaje Estadístico - Parte 2

Manejo de data frames y matrices
Filtrado, ordenamiento y resumen de datos
Visualización básica de datos con gráficos base
Creación de gráficos personalizados
Práctica con R: Manipulación de data frames, gráficos simples y personalizados

Día 3: Simulación de Datos con Patrones Predefinidos

Introducción a la simulación de datos y su importancia
Generación de datos con distribuciones específicas (normal, uniforme, etc.)
Creación de datos con correlaciones y estructuras de dependencia
Generación de datos categóricos y con ruido controlado
Práctica con R: Simulación de conjuntos de datos para diferentes casos de estudio

Lectura: *Roediger et al (2001). Factors that determine false recall: A multiple regression analysis.*
<https://link.springer.com/content/pdf/10.3758/bf03196177.pdf>

Día 4: Regresión Lineal Simple

Conceptos básicos de regresión lineal simple
Ajuste de modelos y interpretación de coeficientes
Evaluación del modelo: R^2 y error cuadrático medio (MSE)
Diagnóstico de supuestos y multicolinealidad
Tamaño de muestra y poder estadístico
Práctica con R: Construcción y evaluación de modelos de regresión lineal simple

Día 5: Regresión Múltiple e Interacciones

Introducción a la regresión múltiple
Modelado con variables categóricas mediante variables ficticias
Interacciones entre variables y su interpretación
Evaluación y diagnóstico de modelos avanzados
Práctica con R: Análisis de regresión múltiple e interacciones

Día 6: Regresión Logística



Introducción a la clasificación y problemas de clasificación
Regresión logística, uso e interpretación
Predicciones a partir de un modelo
Regresión multinomial
Análisis de función discriminante
Práctica con R: Implementación de modelos de clasificación y evaluación de desempeño

Lectura: Chen et al (2023). *Identifying the top determinants of psychological resilience among community older adults during COVID-19 in Taiwan: A random forest approach.*
<https://www.sciencedirect.com/science/article/pii/S2666827023000476>

Día 7: Métodos de Remuestreo y Evaluación de Modelos (Parte I)

Validación cruzada y técnicas de remuestreo
Uso de validación cruzada para evaluar modelos
Medidas de evaluación: matriz de confusión, precisión, recall, índice F1
Práctica con R: Implementación de técnicas de validación cruzada

Día 8: Evaluación de Modelos (Parte II)

Validación cruzada y división de conjuntos de datos
Curvas ROC y AUC: interpretación y uso
Análisis de errores y ajuste de modelos
Comparación y selección de modelos
Práctica con R: Evaluación y comparación de modelos con diferentes métricas

Día 9: Métodos Basados en Árboles

Árboles de decisión: construcción e interpretación
Random forest: fundamentos y aplicaciones
Evaluación de modelos de árboles y comparación con otros métodos
Práctica con R: Construcción y evaluación de modelos basados en árboles

Choi et al. 2020. *Introduction to machine learning, neural networks, and deep learning.*
<https://tvst.arvojournals.org/article.aspx?articleid=2762344>

Día 10: Explorar Espacios Multidimensionales: Reducción de Dimensionalidad

Introducción a la reducción de dimensionalidad y su necesidad
Análisis de Componentes Principales (PCA): teoría y aplicación
Visualización de datos en espacios reducidos
Comparación con otros métodos como t-SNE
Práctica con R: Aplicación de PCA y visualización de resultados

Día 11: Redes Neuronales y Deep Learning - Introducción

Estructura de una red neuronal: neuronas, capas y activación
Entrenamiento de redes neuronales: forward y backpropagation
Introducción a Deep Learning y redes neuronales profundas



Aplicaciones y casos de uso en el mundo real
Práctica con R: Construcción de una red neuronal simple

Día 12: Redes Neuronales y Deep Learning - Aplicaciones Avanzadas

Capas convolucionales y redes neuronales convolucionales (CNNs)
Redes neuronales recurrentes (RNNs) y LSTM
Técnicas de optimización y regularización
Casos de estudio y aplicaciones en visión por computadora y procesamiento de lenguaje natural
Práctica con R: Implementación de una CNN básica y una RNN

Yarkoni & Westfall. 2017. *Choosing prediction over explanation in psychology: Lessons from machine learning*. <https://journals.sagepub.com/doi/pdf/10.1177/1745691617693393>

Día 13: Regularización y Generalización

Conceptos de sobreajuste y subajuste
Regularización: Lasso, Ridge y Elastic Net
Prácticas para evitar el sobreajuste en modelos complejos
Práctica con R: Aplicación de técnicas de regularización y ensamble

Día 14: Aprendizaje No Supervisado: Clustering

Conceptos básicos de clustering y su importancia
Método k-means: algoritmos y aplicaciones
Clustering jerárquico: construcción de dendrogramas
Evaluación de clusters: índice de Silhouette y coeficiente de Rand
Práctica con R: Realización de análisis de clustering en datos de ejemplo

Días 15 y 16: Presentaciones del Proyecto Final

Presentación del proyecto incluyendo una descripción detallada de los análisis de datos

Bibliografía de Referencia

Alpaydin, E. (2020). **Introduction to Machine Learning**. Un recurso introductorio que cubre los conceptos clave y algoritmos en el aprendizaje estadístico, accesible para estudiantes con poca o ninguna experiencia previa. Enlace: <https://www.mitpress.mit.edu/books/introduction-machine-learning>

Badillo, S., Banfai, B., Birzele, F., Davydov, I. I., Hutchinson, L., Kam-Thong, T., Siebourg-Polster J., Steiert B., & Zhang, J. D. (2020). **An introduction to machine learning**. Introduccion general a los metodos de aprendizaje estadístico mas robustos y otros comúnmente utilizados. Enlace: <https://ascpt.onlinelibrary.wiley.com/doi/full/10.1002/cpt.1796>

Bishop, C. M. (2006). **Pattern Recognition and Machine Learning**. Un libro esencial que abarca desde los fundamentos hasta las técnicas avanzadas en reconocimiento de patrones y aprendizaje estadístico. Enlace: <https://www.springer.com/gp/book/9780387310732>



Choi, R. Y., Coyner, A. S., Kalpathy-Cramer, J., Chiang, M. F., & Campbell, J. P. (2020). **Introduction to machine learning, neural networks, and deep learning**. Enlace: <https://tvst.arvojournals.org/article.aspx?articleid=2762344>

Goodfellow, I., Bengio, Y., & Courville, A. (2016). **Deep Learning**. Este libro es una referencia esencial para entender los conceptos fundamentales y avanzados de las redes neuronales y el deep learning. Enlace: <https://www.deeplearningbook.org>

Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2021). **An Introduction to Statistical Learning**. Proporciona una introducción accesible a los métodos estadísticos y de aprendizaje estadístico con aplicaciones prácticas en R. Enlace: <https://www.statlearning.com>

Hastie, T., Tibshirani, R., & Friedman, J. (2009). **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. Un recurso exhaustivo que cubre una amplia gama de métodos de aprendizaje estadístico y computacional, incluyendo teoría y aplicaciones. Enlace: <https://hastie.su.domains/ElemStatLearn/>

Hannes Rosenbusch, Felix Soldner, Anthony M. Evans, Marcel Zeelenberg. (2024). **Supervised machine learning methods in psychology: A practical introduction with annotated R code**. Introducción general al aprendizaje estadístico supervisado en R. Enlace: <https://compass.onlinelibrary.wiley.com/doi/full/10.1111/spc3.12579>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). **An Introduction to Statistical Learning with Applications in R**. Un texto fundamental que cubre una amplia gama de técnicas de aprendizaje estadístico y computacional, con ejemplos prácticos en R. Enlace: <https://www.statlearning.com>

Kuhn, M., & Johnson, K. (2013). **Applied Predictive Modeling**. Este libro proporciona una guía práctica para la construcción de modelos predictivos utilizando R, con un enfoque en la preparación de datos y la selección de modelos. Enlace: <https://www.springer.com/gp/book/9781461468486>

Murphy, K. P. (2012). **Machine Learning: A Probabilistic Perspective**. Ofrece una visión integral del aprendizaje estadístico desde una perspectiva probabilística, con numerosos ejemplos y ejercicios prácticos. Enlace: <https://mitpress.mit.edu/books/machine-learning>

Shalev-Shwartz, S., & Ben-David, S. (2014). **Understanding Machine Learning: From Theory to Algorithms**. Una introducción teórica sólida a los principios y algoritmos del aprendizaje estadístico. Enlace: <https://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning/>

Wickham, H., & Grolemund, G. (2017). **R for Data Science: Import, Tidy, Transform, Visualize, and Model Data**. Aunque centrado en tidyverse, es útil para comprender el flujo de trabajo en R y cómo aplicar principios de limpieza y visualización de datos. Enlace: <https://r4ds.had.co.nz>

Yarkoni, T., & Westfall, J. (2017). **Choosing prediction over explanation in psychology: Lessons from machine learning**. Este artículo trata de las ventajas que puede traer el uso de herramientas de aprendizaje estadístico en la investigación en psicología. Enlace: <https://journals.sagepub.com/doi/pdf/10.1177/1745691617693393>